

Рекомендательное письмо

Я, Дмитрий Солодуха, руководитель команды голосовой активации Алисы, рекомендую Бородину Матвея Вячеславовича для поступления в магистратуру по, связанному с машинным обучением, искусственным интеллектом и обработкой речи.

Матвей проходил стажировку в Яндексе с мая по июль 2026 года в качестве ML-разработчика в команде голосовой активации. Наша команда разрабатывает модели, которые работают на умных устройствах Яндекса и в потоковом режиме определяют обращение пользователя к Алисе. Они должны обеспечивать высокое качество детекции при жестких ограничениях по вычислительной сложности, памяти, скорости обработки аудиопотока и задержке.

Основной задачей Матвея была разработка новой архитектуры моделей голосовой активации с использованием multi-head self-attention и трансформеров. Архитектура должна была улучшить качество детекции, сохранив целевой ресурсный профиль и задержку. Для этого требовалось адаптировать трансформеры к потоковому инференсу, ограниченному контексту и вычислительным возможностям умной колонки. Задача носила открытый исследовательско-инженерный характер и не имела готового решения.

Особенно хочу отметить самостоятельность Матвея. Он выстроил работу как полноценное исследование: провел обзор профильных научных работ, сформулировал гипотезы и организовал систематический экспериментальный поиск по различным вариантам архитектуры. Матвей оценивал применимость подходов к короткому потоковому аудиоконтексту, анализировал компромисс между качеством и ресурсами и по результатам сам определял дальнейшее направление работы. Мне не требовалось детально декомпозировать задачу или контролировать отдельные этапы.

Результатом стала компактная гибридная архитектура со свертками и трансформерными энкодер-блоками: сверточные слои извлекают локальные акустические и спектральные признаки, а механизм внимания агрегирует более высокоуровневую информацию во временном контексте. Каждый энкодер-блок построен по pre-post схеме: RMSNorm применяется перед attention слоем и перед feed-forward блоком, что способствует устойчивому обучению. QK-нормализация с обучаемым масштабированием контролирует величину логитов, локальная маска ограничивает прошлый и будущий контекст и сокращает вычисления, а относительные позиционные смещения вместе с RoPE кодируют взаимное расположение фреймов. Итоговая конфигурация была выбрана экспериментально и стала осмысленной адаптацией трансформеров к голосовой активации.

Матвей самостоятельно довел модель до исполнения на устройстве. Он написал и покрыл тестами реализацию attention, а для обучения разработал блочную реализацию локального внимания по принципам FlashAttention, в которой вычисления выполняются по блокам без формирования полной матрицы QK в памяти. Эта оптимизация существенно снизила пиковое потребление GPU-памяти и позволила проводить полный цикл обучения на доступных команде 40 ГБ картах, включая NVIDIA A100, без зависимости от редких конфигураций с увеличенным объемом памяти. Матвей также реализовал конкатенацию модели из PyTorch в квантованный формат TFLite INT8 без потери качества и потоковый инференс с KV-кэшированием: переиспользование представлений обрабатываемых фреймов снижает вычислительную нагрузку и объем состояния модели на устройстве.

Проверку решения Матвей также организовал самостоятельно: провел офлайн-оценку качества и ресурсов, вывел несколько моделей в бета-контур и лично подготовил их запуск в A/B-экспериментах. Модели улучшили целевые метрики голосовой активации, снизили вычислительную сложность по числу операций MAC и сохранили остальные ресурсные характеристики и задержку в требуемом диапазоне.

Результаты Матвея принесли команде существенную практическую пользу. Мы получили не изолированный исследовательский прототип, а проверенную архитектуру, рабочие реализации обучения, конвертации и потокового инференса, а также воспроизводимые экспериментальные выводы. Его работа показала, что attention можно эффективно использовать в моделях голосовой активации в рамках ограничений реального устройства, и расширила набор архитектурных решений, доступных команде.

По степени независимости, качеству технических решений и ответственности за результат Матвей работал на уровне самостоятельного ML-инженера и исследователя. Ему можно доверить новое направление с неопределенной постановкой: он способен сам изучить предметную область, предложить решение, качественно реализовать его, проверить на нескольких уровнях и довести до продуктового эксперимента. Я высоко оцениваю его техническую экспертизу, профессиональную зрелость и вклад в развитие моделей голосовой активации.

Считаю, что опыт Матвея на пересечении машинного обучения, обработки речи и оптимизации моделей для устройств хорошо соответствует академической и исследовательской траектории магистратуры. Он обладает сильной технической базой, умеет проводить воспроизводимые эксперименты и уже доказал способность приносить практическую пользу в сложных исследовательских задачах.

Рекомендую Бородину Матвея Вячеславовича к поступлению в магистратуру.

С уважением,
Дмитрий Солодуха
Руководитель команды голосовой активации
Яндекс
dsoloduha@yandex-team.ru
15 июля 2026 года

